Jour 42 : Startups dans le Marketing

La base de données utilisée dans ce cas pratique renseigne sur quelques variables de l'activité économique de 50 Startups béninoises. Il s'agit des dépenses en Recherche et développement, Administration, Marketing, la ville de résidence et le profit généré.

0. Chargement des librairies

In [1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.preprocessing import LabelEncoder, OneHotEncoder
from sklearn.compose import ColumnTransformer

from sklearn.linear_model import LinearRegression

from sklearn.metrics import r2_score
```

1. Importation de la base de données et vérification des valeurs manquantes

1.1. Importation de la base de données

In [2]:
```
import pandas as pd
df = pd.read_csv("../data/50_Startups_Multiple.csv")
df.head()
```

Out[2]:

	R&D Spend	Administration	Marketing Spend	State	Profit
0	165349.20	136897.80	471784.10	Cotonou	192261.83
1	162597.70	151377.59	443898.53	Ouidah	191792.06
2	153441.51	101145.55	407934.54	Parakou	191050.39
3	144372.41	118671.85	383199.62	Cotonou	182901.99
4	142107.34	91391.77	366168.42	Parakou	166187.94

1.2. Vérification des valeurs manquantes

In [3]:
```
print(df.isnull().sum())
```

```
R&D Spend          0
Administration     0
Marketing Spend    0
State              0
Profit             0
dtype: int64
```

In [4]:
```
df.describe().transpose()
```

Out[4]:

	count	mean	std	min	25%	50%
R&D Spend	50.0	73721.6156	45902.256482	0.00	39936.3700	73051.080
Administration	50.0	121344.6396	28017.802755	51283.14	103730.8750	122699.795
Marketing Spend	50.0	211025.0978	122290.310726	0.00	129300.1325	212716.240
Profit	50.0	112012.6392	40306.180338	14681.40	90138.9025	107978.190

La base de données ne contient aucune valeur manquante.

2. Traitement des variables catégorielles

2.1. Visualisation de la variable State

In [5]:
```
# Boxplot de Profit par ville
import matplotlib.pyplot as plt
import seaborn as sns
plt.figure(figsize=(8, 6))
sns.boxplot(x=df['State'], y=df['Profit'])
plt.title('Profit par ville')
plt.xlabel('Ville')
plt.ylabel('Profit')
plt.show()
```

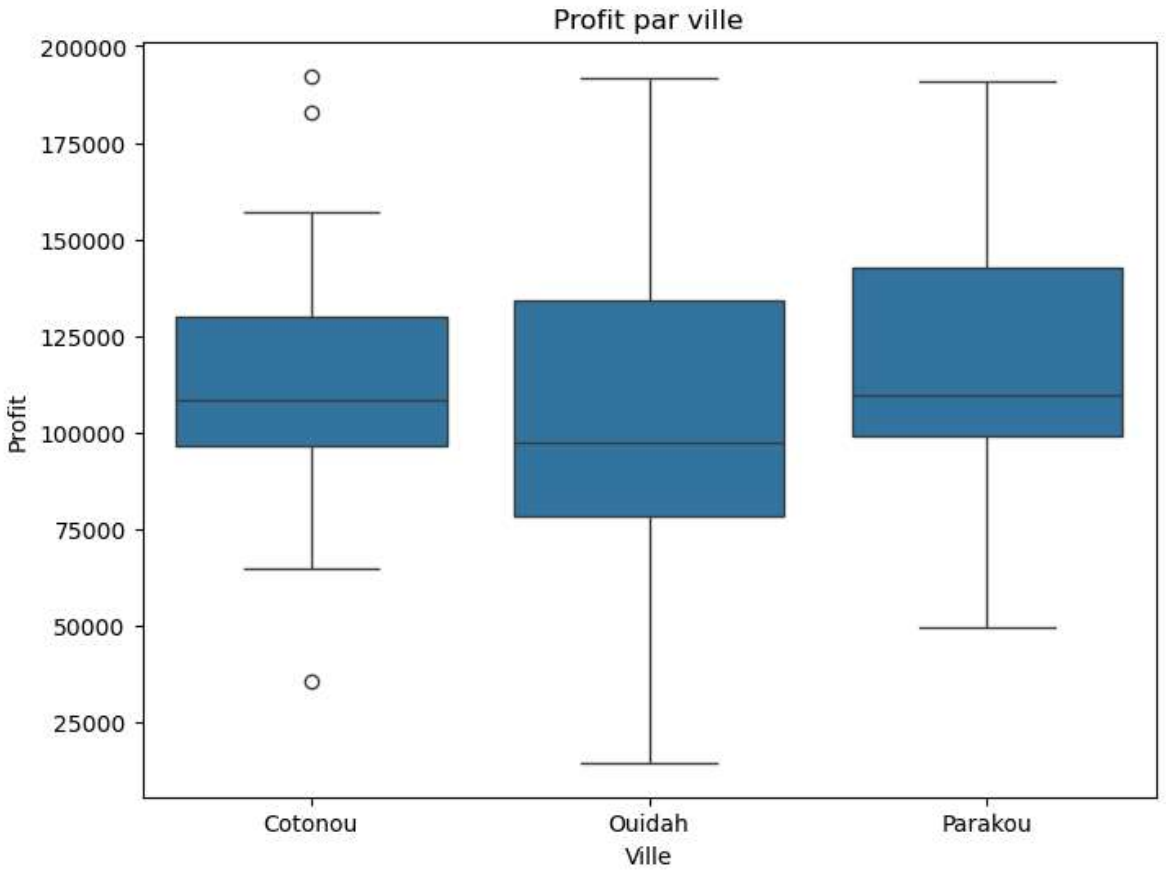

La distribution des profits des entreprises étudiées à Cotonou, présente des valeurs aberrantes.

2.2. Encodage de la variable catégorielle

In [6]:
```
X = df.iloc[:,:-1].values
y = df.iloc[:,-1].values

from sklearn.preprocessing import LabelEncoder, OneHotEncoder
labelEncoder = LabelEncoder()

X[:,3] = labelEncoder.fit_transform(X[:,3])

ct = ColumnTransformer([("auto", OneHotEncoder(), [-1])], remainder = 'passthrou
X = ct.fit_transform(X)
```

3. Division du dataset

In [7]:
```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_
```

4. Construction du modèle

In [8]:
```
from sklearn.linear_model import LinearRegression
import statsmodels.api as sm
regressor = LinearRegression().fit(X_train, y_train)
print("Coefficients:", regressor.coef_)
print("Intercept:", regressor.intercept_)
```

```
Coefficients: [-1.64602649e+03  2.17532903e+03 -5.29302538e+02  8.26989976e-01
 -5.47084490e-02  2.05751030e-02]
Intercept: 53491.98107666568
```

Les coefficients représentent l'impact de chaque variable indépendante sur la variable dépendante (ici le profit). L'intercept représente la valeur prédite du profit lorsque toutes les variables indépendantes sont égales à zéro. Dans notre cas, si toutes les dépenses (R&D, Administration, Marketing) sont nulles et que la ville n'est pas spécifiée, le profit prédit serait d'environ 53 491,98.

In [9]:
```
# Calcul du coefficient de détermination

y_pred = regressor.predict(X_test)

r2 = r2_score(y_test, y_pred)

print(r2)
```

```
0.9045543891702044
```

Les dépenses en R&D, administration et marketing, ainsi que la ville de résidence d'une entreprise, permettent d'expliquer à 90% la variabilité du profit généré par l'entreprise.

5. Prédiction

On se propose de prédire le profit avec les critères suivants :

- RD : 175000;
- Administration : 90000;
- Marketing : 45000;
- State : Ouidah.

In [10]:
```
print(regressor.predict([[0, 1, 0, 175000, 90000, 45000]]))
```

```
[196392.67506606]
```

Le modèle prédit que, pour les critères donnés, le profit attendu est d'environ 196 392,68. Cela signifie que, selon les données historiques et le modèle entraîné, une entreprise avec ces caractéristiques (dépenses en R&D, administration, marketing, et située à Ouidah) devrait générer un profit proche de la valeur obtenue.